

실습 가이드 2 · RAG 1 — 저장과 검색 5단계 직접 관찰

목표: RAG 5단계(파싱·청킹·임베딩·검색·생성)를 눈으로 확인하고, BM25·하이브리드 검색을 직접 붙여본다.

원본은 [학습노트 02](#) 참고. 원본은 배부된 [rag-lab.zip](#) (완성 앱)을 풀어서 시작하지만, 자습에서는 **Claude Code**에게 동등한 앱을 직접 만들게 합니다 — 오히려 "이미 만들어진 앱 파악하기"가 아니라 "요구사항으로 앱 만들기" 연습이 한 번 더 됩니다.

준비물

- 본인 PDF 문서 3~5개 (표·절 번호가 섞인 것일수록 학습 효과 좋음 — 회사 매뉴얼, 논문, 계약서, 보고서 등)

체크리스트

1. 폴더 생성 & 앱 부트스트랩

```
mkdir C:\ai-agent-selfstudy\02-rag-lab
cd C:\ai-agent-selfstudy\02-rag-lab
claude
```

아래 지시문을 그대로 붙여넣습니다 (rag-lab의 핵심 기능을 압축한 사양):

로컬 문서 기반 RAG 실습용 웹앱을 만들어줘. 파이썬(FastAPI 또는 Flask)+간단한 웹 UI로.

[화면 구성 - 탭 4개]

- ① 문서 탭: PDF 업로드. 업로드하면 페이지별로 추출된 글자 수를 막대그래프로 보여줘.
글자가 거의 안 나온 페이지는 빨간색으로 표시하고, 눌러서 그 페이지 원문(파싱 결과)을 볼 수 있게 해줘.
- ② 청킹 탭: "고정 길이" / "구조 경계(제목·번호)" / "문단" 세 가지 기준을 선택해 미리보기 가능하게 해줘.
각 기준으로 조각(청크) 개수, 최장/최단 길이를 보여주고, 청크 카드를 눌러 전문을 펼칠 수 있게 해줘.
- ③ 임베딩 탭: [적재] 버튼 - 선택한 청킹 기준으로 청크를 만들고, OpenAI 임베딩 API(text-embedding-3-sm) 벡터화해서 로컬 벡터 저장소(chromadb 사용)에 저장해줘. 적재된 청크 수를 화면에 표시해줘.
- ④ 검색 탭: 질문을 입력하면 의미 검색으로 가장 가까운 청크 5개를 유사도 점수와 함께 보여줘.
각 청크를 펼치면 출처 문서명과 페이지 번호가 보이게 해줘.
[답변 생성] 토글 - 켜면 검색된 청크 + 질문을 OpenAI 모델에 넘겨 답변을 생성하고,
답변 아래에 실제 프롬프트로 들어간 글자 수도 표시해줘.

[공통]

- .env 파일에서 OPENAI_API_KEY 를 읽어서 쓰고, .gitignore 에 .env 추가해줘.
- 청크에는 문서명·페이지·청킹기준 메타데이터를 함께 저장해줘 (나중에 필터링에 씀).
- 상태 표시줄에 지금까지 적재된 문서 수와 청크 수를 항상 보여줘.
- 다 만들면 실행 방법을 알려주고 서버를 실행해줘.

- [.env](#) 만들어달라고 요청 후 본인 OpenAI 키 입력

- 앱 실행 확인 (Claude Code가 알려준 주소로 브라우저 접속)

2. naive RAG 단계별 관찰

- PDF 3~5개를 하나씩 업로드 → ① 탭에서 페이지별 추출 글자 수 확인, 빨간 칸(추출 실패 페이지) 있으면 원문과 대조
- ② 탭에서 같은 문서를 3가지 청킹 기준으로 각각 미리보기 → 청크 개수·길이 비교, 문장이 중간에서 끊긴 조각 찾아보기
- ③ 탭에서 [적재] — 문서 전부 적재, 청크 수 확인
- ④ 탭에서 문서 내용에 대한 질문을 한국어로/영어로(문서가 영어라면) 각각 던져 비교
- [답변 생성] 켜고 같은 질문 재실행 → 답변과 근거 청크 대조
- 문서에 없는 내용을 일부러 질문 → 환각 여부 확인
- 표나 그림 관련 내용을 질문 → 파싱에서 누락됐는지 확인

3. BM25 + 하이브리드 검색 추가

이 앱의 검색 화면에 **BM25**(키워드) 검색을 추가해줘.
검색 화면에서 의미 검색과 **BM25** 검색 결과를 좌우로 나란히 볼 수 있게 구현해줘.

(서버 재시작 후) 단어만 넣어 테스트: 문서에 나오는 고유명사, 숫자·기호가 섞인 표현, 오타 등

의미 검색과 **BM25**의 결과를 하나로 합치는 하이브리드 검색을 추가해 줘.
점수를 그대로 더하지 말고 순위로 결합해 줘.
검색 화면에 [의미 검색] [BM25] [하이브리드] 세 열을 나란히 보여 줘.

4. 문서 추가 후 재질문

- 판(버전)이나 항목명이 비슷한 문서를 하나 더 적재 (또는 같은 문서의 개정판이 있다면 함께)
- 애매하게 겹칠 만한 질문을 던져 답변·근거 5개의 출처를 기록해두기 → 이 기록이 3교시(실습 가이드 3)의 출발점

완료 기준

- 파싱·청킹·임베딩·검색·생성 5단계를 전부 화면에서 관찰함
- BM25·하이브리드 검색이 동작하고 세 결과를 비교해봄
- "판이 다른 문서가 섞였을 때 답이 흔들리는" 사례를 최소 1개 기록함

막히면

증상	해결
chromadb 설치 오류	Claude Code에게 "chromadb 설치 오류 해결해줘"

증상	해결
코드 수정 후 반영 안 됨	서버 재시작(Ctrl+C 후 재실행)
PDF에서 표가 텍스트로 안 뽑힘	정상적인 현상 — 3교시에서 다룸

다음: [03-RAG2 실습 가이드](#) (같은 **rag-lab** 폴더에서 이어서 진행)